

08IrTheory

November 4, 2018

1 英文 NLP 基礎教學

```
In [1]: import pandas as pd
```

```
import nltk

from nltk.stem.porter import PorterStemmer
porter_stemmer = PorterStemmer()
from nltk.stem.lancaster import LancasterStemmer
lancaster_stemmer = LancasterStemmer()
from nltk.stem import SnowballStemmer
snowball_stemmer = SnowballStemmer('english')
from nltk.stem import WordNetLemmatizer
wordnet_lemmatizer = WordNetLemmatizer()

from nltk.corpus import stopwords
stops = stopwords.words('english')
from string import punctuation
```

```
In [2]: testStr = "This value is also called cut-off in the literature. If float, the parameter represents a proportion of the total number of words in the document."
# 請使用 nltk.word_tokenize 及 nltk.wordpunct_tokenize 進行分詞，並比較其中差異。
#=====your works starts=====#
word_tokenize_tokens = nltk.word_tokenize(testStr)
wordpunct_tokenize_tokens = nltk.wordpunct_tokenize(testStr)
#=====your works ends=====#

print("/".join(word_tokenize_tokens))
print("/".join(wordpunct_tokenize_tokens))
# This/value/is/also/called/cut-off/in/the/literature/./If/float/,/the/parameter/represents/a/proportion/of/the/total/number/of/words/in/the/document./
# This/value/is/also/called/cut/-/off/in/the/literature/./If/float/,/the/parameter/represents/a/proportion/of/the/total/number/of/words/in/the/document./
```

```
This/value/is/also/called/cut-off/in/the/literature/./If/float/,/the/parameter/represents/a/proportion/of/the/total/number/of/words/in/the/document./
This/value/is/also/called/cut/-/off/in/the/literature/./If/float/,/the/parameter/represents/a/proportion/of/the/total/number/of/words/in/the/document./
```

```
In [3]: tokens = wordpunct_tokenize_tokens
df = pd.DataFrame(index = tokens)
```

```
# 請使用 porter_stemmer, lancaster_stemmer, snowball_stemmer, wordnet_lemmatizer 進行
#=====your works starts=====#
df['porter_stemmer'] = [porter_stemmer.stem(t) for t in tokens]
df['lancaster_stemmer'] = [lancaster_stemmer.stem(t) for t in tokens]
df['snowball_stemmer'] = [snowball_stemmer.stem(t) for t in tokens]
df['wordnet_lemmatizer'] = [wordnet_lemmatizer.lemmatize(t) for t in tokens]
#=====your works ends=====#

print(df.iloc[0].tolist())
print(df.iloc[1].tolist())
# ['thi', 'thi', 'this', 'This']
# ['valu', 'valu', 'valu', 'value']
```

df

```
['thi', 'thi', 'this', 'This']
['valu', 'valu', 'valu', 'value']
```

```
Out[3]:
```

	porter_stemmer	lancaster_stemmer	snowball_stemmer	\
This	thi	thi	this	
value	valu	valu	valu	
is	is	is	is	
also	also	also	also	
called	call	cal	call	
cut	cut	cut	cut	
-	-	-	-	
off	off	off	off	
in	in	in	in	
the	the	the	the	
literature	literatur	lit	literatur	
.	.	.	.	
If	If	if	if	
float	float	flo	float	
,	,	,	,	
the	the	the	the	
parameter	paramet	paramet	paramet	
represents	repres	repres	repres	
a	a	a	a	
proportion	proport	proport	proport	
of	of	of	of	
documents	document	docu	document	
,	,	,	,	
integer	integ	integ	integ	
absolute	absolut	absolv	absolut	
counts	count	count	count	
.	.	.	.	

	wordnet_lemmatizer
This	This
value	value
is	is
also	also
called	called
cut	cut
-	-
off	off
in	in
the	the
literature	literature
.	.
If	If
float	float
,	,
the	the
parameter	parameter
represents	represents
a	a
proportion	proportion
of	of
documents	document
,	,
integer	integer
absolute	absolute
counts	count
.	.

```
In [4]: print("標點符號")
        print(punctuation)
        print("停用字")
        print(stops)
```

標點符號

!"#\$%&'()*+,-./:;<=>?@[\\]^_`{|}~

停用字

['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "you're", "you've", "you'"]

```
In [5]: df = pd.DataFrame(index = [t for t in tokens if t not in stops and t not in punctuation
# 請使用 porter_stemmer, lancaster_stemmer, snowball_stemmer, wordnet_lemmatizer 進行
# 請去除標點符號與停用字
#=====your works starts=====#
df['porter_stemmer'] = [porter_stemmer.stem(t.lower()) for t in tokens if t not in stops
df['lancaster_stemmer'] = [lancaster_stemmer.stem(t.lower()) for t in tokens if t not in stops
df['snowball_stemmer'] = [snowball_stemmer.stem(t.lower()) for t in tokens if t not in stops
df['wordnet_lemmatizer'] = [wordnet_lemmatizer.lemmatize(t.lower()) for t in tokens if t not in stops and t not in punctuation])
```

```
#=====your works ends=====
```

```
df
```

```
Out [5]:      porter_stemmer  lancaster_stemmer  snowball_stemmer  \
This          thi          thi          this
value        valu          valu          valu
also          also          also          also
called        call          cal          call
cut           cut          cut          cut
literature    literatur    lit          literatur
If            if          if          if
float         float        flo          float
parameter     paramet      paramet      paramet
represents    repres      repres      repres
proportion    proport      proport      proport
documents     document     docu         document
integer       integ        integ        integ
absolute      absolut      absolut      absolut
counts        count        count        count
```

```
      wordnet_lemmatizer
This          this
value         value
also          also
called        called
cut           cut
literature    literature
If            if
float         float
parameter     parameter
represents    represents
proportion    proportion
documents     document
integer       integer
absolute      absolute
counts        count
```

```
In [6]: df_tag = pd.DataFrame(index = tokens)
# 請使用 nltk.pos_tag 進行詞性標記，並嘗試設定參數 tagset='universal'
#=====your works starts=====
df_tag['default'] = [tag for term, tag in nltk.pos_tag(tokens)]
df_tag['universal'] = [tag for term, tag in nltk.pos_tag(tokens, tagset='universal')]
#=====your works ends=====
```

```
df_tag
```

```
Out [6]:      default  universal
This          DT          DET
```

value	NN	NOUN
is	VBZ	VERB
also	RB	ADV
called	VBN	VERB
cut	VBN	VERB
-	:	.
off	RB	ADV
in	IN	ADP
the	DT	DET
literature	NN	NOUN
.	.	.
If	IN	ADP
float	NN	NOUN
,	,	.
the	DT	DET
parameter	NN	NOUN
represents	VBZ	VERB
a	DT	DET
proportion	NN	NOUN
of	IN	ADP
documents	NNS	NOUN
,	,	.
integer	NN	NOUN
absolute	NN	NOUN
counts	NNS	NOUN
.	.	.

2 建立詞向量

```
In [7]: import numpy as np
import pandas as pd
import nltk
from nltk.stem.porter import PorterStemmer
porter_stemmer = PorterStemmer()
```

```
from nltk.corpus import stopwords
stops = stopwords.words('english')
from string import punctuation
```

```
In [8]: corpus = ["what time is it?", "how long has it been since we started?", "that's a long
df = pd.DataFrame(corpus, columns=['sentence'])
df
```

```
Out[8]:
```

	sentence
0	what time is it?
1	how long has it been since we started?
2	that's a long time ago

```
In [9]: # 請使用 nltk.word_tokenize 將每一行的詞彙切開
#=====your works starts=====#
df['tokenize'] = df['sentence'].apply(nltk.word_tokenize)
#=====your works ends=====#

df['tokenize']
# 0 [what, time, is, it, ?]
# 1 [how, long, has, it, been, since, we, started, ?]
# 2 [that, 's, a, long, time, ago]
# Name: tokenize, dtype: object
```

```
Out[9]: 0 [what, time, is, it, ?]
1 [how, long, has, it, been, since, we, started, ?]
2 [that, 's, a, long, time, ago]
Name: tokenize, dtype: object
```

```
In [10]: # 請找出不重複的所有出現過的字
#=====your works starts=====#
word_index = set(np.hstack([tokens for tokens in df['tokenize']]))
#=====your works ends=====#

print("len(word_index)", len(word_index))
print(word_index)
# len(word_index) 16
# {'is', 'that', 'time', 'long', 'we', 'ago', 'started', 'has', 'been', 'a', "'s", 'h'
```

```
len(word_index) 16
{'long', 'what', "'s", 'that', 'time', 'ago', 'since', '?', 'a', 'started', 'has', 'how', 'we'
```

```
In [11]: for column in word_index:
# 請幫每一個字創造一個欄位並指派為 0
#=====your works starts=====#
df[column] = 0
#=====your works ends=====#

print(df.columns)
df
# Index(['sentence', 'tokenize', 'is', 'that', 'time', 'long', 'we', 'ago',
#       'started', 'has', 'been', 'a', "'s", 'how', 'what', 'it', 'since', '?'],
#       dtype='object')

Index(['sentence', 'tokenize', 'long', 'what', "'s", 'that', 'time', 'ago',
      'since', '?', 'a', 'started', 'has', 'how', 'we', 'it', 'been', 'is'],
      dtype='object')
```

```
Out[11]:
```

	sentence \												
0	what time is it?												
1	how long has it been since we started?												
2	that's a long time ago												

		tokenize	long	what	's	that	\						
0	[what, time, is, it, ?]	0	0	0	0	0	0						
1	[how, long, has, it, been, since, we, started, ?]	0	0	0	0	0	0						
2	[that, 's, a, long, time, ago]	0	0	0	0	0	0						

	time	ago	since	?	a	started	has	how	we	it	been	is	
0	0	0	0	0	0	0	0	0	0	0	0	0	
1	0	0	0	0	0	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	0	0	0	0	0	

```
In [12]: def build_word_index(row):  
    tokens = row['tokenize']  
    for token in tokens:  
        # 請幫計算每個字，在這個句子中出現的次數  
        #=====your works starts=====#  
        row[token] += 1  
        #=====your works ends=====#  
    return row  
  
df_processed = df.apply(build_word_index, axis=1)  
  
print(df_processed.iloc[0].tolist())  
# ['what time is it?', ['what', 'time', 'is', 'it', '?'], 1, 0, 1, 0, 0, 0, 0, 0, 0, 0,  
df_processed  
  
['what time is it?', ['what', 'time', 'is', 'it', '?'], 0, 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0,
```

3 中文 NLP 教學

```
In [13]: import jieba
jieba.set_dictionary('dict.txt.big') # 如果是使用繁體文字，請記得去下載繁體字典來使用
with open('stops.txt', 'r', encoding='utf8') as f: # 中文的停用字，我也忘記從哪裡拿到的
    stops = f.read().split('\n')
```

```
In [14]: # 請使用 jieba.cut 進行斷詞，並嘗試使用全斷詞模式 (cut_all=True)
#=====your works starts=====#
result_cut = [t for t in jieba.cut('下雨天留客天留我不留')]
result_cutall = [t for t in jieba.cut('下雨天留客天留我不留', cut_all=True)]
#=====your works ends=====#

print(result_cut)
print(result_cutall)
# [' 下雨天', ' 留客', ' 天留', ' 我', ' 不留']
# [' 下雨', ' 下雨天', ' 雨天', ' 留客', ' 天', ' 留', ' 我', ' 不留']
```

Building prefix dict from D:\Projects\IIIMaterial\08_IrTheory\dict.txt.big ...

Loading model from cache C:\Users\user\AppData\Local\Temp\jieba.u113aa1b94b8c59a47d44fb9a8d37f...

Loading model cost 1.589 seconds.

Prefix dict has been built successfully.

```
[' 下雨天', ' 留客', ' 天留', ' 我', ' 不留']
[' 下雨', ' 下雨天', ' 雨天', ' 留客', ' 天', ' 留', ' 我', ' 不留']
```

```
In [15]: print("停用字")
print(stops[:100])
```

停用字

```
['\uffeff\uffeff', ',', "'", '、', '。', '“', '”', '《', '》', '!', '!', ':', ';', '?', '人民',
```

```
In [16]: from collections import Counter
from wordcloud import WordCloud
from matplotlib import pyplot as plt
```

testStr = """自然語言處理大體是從 1950 年代開始，雖然更早期也有作為。1950 年，圖靈發表論
1954 年的喬治城實驗涉及全部自動翻譯超過 60 句俄文成為英文。研究人員聲稱三到五年之內即可解
1960 年代發展特別成功的 NLP 系統包括 SHRDLU——一個詞彙設限、運作於受限如「積木世界」的一
1970 年代，程式設計師開始設計「概念本體論」(conceptual ontologies) 的程式，將現實世界的資
一直到 1980 年代，多數自然語言處理系統是以一套複雜、人工訂定的規則為基礎。不過從 1980 年
許多早期的成功屬於機器翻譯領域，尤其歸功 IBM 的研究，漸次發展出更複雜的統計模型。這些系統
近來的研究更加聚焦於非監督式學習和半監督學習的演算法。這種演算法，能夠從沒有人工註解理想答
近年來，深度學習技巧紛紛出爐 [2] [3] 在自然語言處理方面獲得最尖端的成果，例如語言模型 [4]，

[(' 語言', 10), (' 學習', 10), (' 機器', 9), (' 研究', 8), (' 系統', 8), (' 資料', 8), (' 翻譯',

[illegible]

9

```
plt.figure()
plt.imshow(alice_mask, cmap=plt.cm.gray, interpolation='bilinear')
plt.axis("off")
plt.show()
```



4 中文檢索系統

1. TFIDF

$$TFIDF_{td} = TF_{td} \times \log\left(\frac{N}{DF_t}\right)$$

- 所謂 TFIDF 應分成兩個部分來理解：TF(Term Frequency) 以及 IDF(Inverted Document Frequency)。
- TF(Term Frequency): TF_{td} 指得是在特定的文章 d 中特定的字 t 出現了幾次。這個部分同時，也表示了一個文字在一篇文章的重要性，依但出現越多次，這個字也就越能代表這篇文章。
- IDF(Inverted Document Frequency): N 指得是總共有幾篇文章， DF_t 中的 DF 是 Document Frequency 的意思， DF_t 則是詞彙 t 在幾篇文章中出現過。 $\frac{N}{DF_t}$ 也就是所有文章當中，詞彙 t 在幾篇文章出現過，而其倒數則是 Inverted Document Index，表著這個詞彙如果在很多文章裏面都出現過，則其重要性會受到懲罰，而取 \log 則只是讓他在分數的影響上比較平滑而已。

2. Cosine Similarity

$$\cos \theta = \frac{A \cdot B}{\|A\|_2 \|B\|_2}$$

- if $A = [1, 2, 0, 4]$ and $B = [3, 2, 1, 0]$
- $\cos \theta = \frac{1 \cdot 3 + 2 \cdot 2 + 0 \cdot 1 + 4 \cdot 0}{\sqrt{1^2 + 2^2 + 0^2 + 4^2} \cdot \sqrt{3^2 + 2^2 + 1^2 + 0^2}}$

```
In [19]: import jieba
jieba.set_dictionary('dict.txt.big') # 如果是使用繁體文字，請記得去下載繁體字典來使用
import numpy as np
import pandas as pd
```

```
In [20]: # 把檔案讀出來 (原始資料: https://society.hccg.gov.tw/ch/home.jsp?id=43&parentpath=0,5)
df_QA = pd.read_json('ProcessedData.json', encoding='utf8')
# 我們這次只會使用到 question 跟 ans 這兩個欄位
df_question = df_QA[['question', 'ans']].copy() ## 不要更動到原始的 DataFrame
df_question.drop_duplicates(inplace=True) ## 丟掉重複的資料
df_question.head(5) ## show 出來
```

```
Out[20]:
```

	question \
0	小孩出生後應於何時申請育兒津貼?
1	小孩出生後應於何時申請育兒津貼?
2	育兒津貼申請應備文件為何?
3	若民眾夫妻雙方均失業，是否可申請家庭育兒津貼費用補助
4	育兒津貼補助對象為何？

	ans
0	1. 幼兒家長在戶政事務所完成新生兒出生登記後，即可向所轄區公所社政課提出育兒津貼申請。2
1	隨時提出；津貼經審查通過後，追溯自受理申請之當月起發給。兒童出生後六十日內向戶政事務所
2	申請資料應備齊：(一) 兒童之戶口名簿影本。(二) 申請人之郵局存摺封面影本。(三) 父母雙方身
3	一、育兒津貼補助對象：1. 育有二足歲以下兒童。2. 兒童之父母至少一方因育兒需要，致未能就
4	育兒津貼補助對象，應符合下列規定：(一) 育有二足歲以下兒童。(二) 兒童之父母（或監護人）

```

In [21]: # 前處理
all_terms = []
def preprocess(item): ## 定義前處理的 function
    # 請把將每一行用 jieba.cut 進行分詞 (記得將 cut_all 設定為 True)
    # 同時建立所有詞彙的 list(all_terms)
    #=====your works starts=====#
    terms = [t for t in jieba.cut(item, cut_all=True)] ## 把全切分模式打開，可以比對的
    all_terms.extend(terms) ## 收集所有出現過的字
    #=====your works ends=====#
    return terms

df_question['processed'] = df_question['question'].apply(preprocess)
print(df_question.iloc[0])
# question                                     小孩出生後應於何時申請育兒津貼？
# ans                                           1. 幼兒家長在戶政事務所完成新生兒出生登記後，即可向所轄區公所社政課提出育兒
# processed                                     [小孩，出生，後，應於，何時，申請，育兒，津貼，，]
# Name: 0, dtype: object

df_question.head()

```

Building prefix dict from D:\Projects\IIIMaterial\08_IrTheory\dict.txt.big ...
Loading model from cache C:\Users\user\AppData\Local\Temp\jieba.u113aa1b94b8c59a47d44fb9a8d37f...
Loading model cost 1.931 seconds.
Prefix dict has been built successfully.

```

question                                     小孩出生後應於何時申請育兒津貼？
ans                                           1. 幼兒家長在戶政事務所完成新生兒出生登記後，即可向所轄區公所社政課提出育兒津貼申請。
processed                                     [小孩，出生，後，應於，何時，申請，育兒，津貼，，]
Name: 0, dtype: object

```

```

Out[21]:
question \
0      小孩出生後應於何時申請育兒津貼？
1      小孩出生後應於何時申請育兒津貼？
2      育兒津貼申請應備文件為何？
3      若民眾夫妻雙方均失業，是否可申請家庭育兒津貼費用補助
4      育兒津貼補助對象為何？

ans \
0      1. 幼兒家長在戶政事務所完成新生兒出生登記後，即可向所轄區公所社政課提出育兒津貼申請。2
1      隨時提出；津貼經審查通過後，追溯自受理申請之當月起發給。兒童出生後六十日內向戶政事務所
2      申請資料應備齊：(一) 兒童之戶口名簿影本。(二) 申請人之郵局存摺封面影本。(三) 父母雙方身
3      一、育兒津貼補助對象：1. 育有二足歲以下兒童。2. 兒童之父母至少一方因育兒需要，致未能就
4      育兒津貼補助對象，應符合下列規定：(一) 育有二足歲以下兒童。(二) 兒童之父母（或監護人）

processed
0      [小孩，出生，後，應於，何時，申請，育兒，津貼，，]

```

```

1             [小孩, 出生, 後, 應於, 何時, 申請, 育兒, 津貼, , ]
2             [育兒, 津貼, 申請, 應, 備, 文件, 為, 何, , ]
3 [若, 民, 眾, 夫妻, 雙方, 均, 失業, , , 是否, 可, 申請, 家庭, 育兒...
4             [育兒, 津貼, 貼補, 補助, 對象, 為, 何, , ]

```

```

In [22]: # 建立 termindex: 將 all_terms 取出不重複的詞彙, 並轉換型別為 list(避免順序亂掉)
#=====your works starts=====#
termindex = list(set(all_terms))
#=====your works ends=====#

print("len(termindex)", len(termindex))
print(termindex[:10])
# len(termindex) 1012
# ['', ' 耗材', ' 被', ' 其他', ' 發', ' 發現', ' 申請人', ' 遭遇', ' 環境', ' 您好']

len(termindex) 1012
['', ' 證', ' 災害', ' 重要', ' 之人', ' 偶或', ' 到', ' 民', ' 耗材', ' 幫忙']

```

```

In [23]: # 建立 IDF vector
Doc_Length = len(df_question) ## 計算出共有幾篇文章
Idf_vector = [] ## 初始化 IDF 向量
for term in termindex: ## 對 index 中的詞彙跑回圈
    num_of_doc_contains_term = 0 ## 計算有機篇文章出現過這個詞彙
    for terms in df_question['processed']:
        if term in terms:
            num_of_doc_contains_term += 1
    idf = np.log(Doc_Length/num_of_doc_contains_term) ## 計算該詞彙的 IDF 值
    Idf_vector.append(idf)
print(len(Idf_vector))
print(Idf_vector[:10])

1012
[0.04710446918747347, 5.093750200806762, 5.786897381366708, 5.786897381366708, 5.786897381366708,

```

```

In [24]: # 建立 document vector
def terms_to_vector(terms): ## 定義把 terms 轉換成向量的 function
    ## 建立一條與 termsindex 等長、但值全部為零的向量 (hint: dtype=np.float32)
    #=====your works starts=====#
    vector = np.zeros_like(termindex, dtype=np.float32)
    #=====your works ends=====#

    for term, count in Counter(terms).items():
        # 計算 vector 上每一個字的 tf 值
        #=====your works starts=====#
        vector[termindex.index(term)] = count
        #=====your works ends=====#

```

```

# 計算 tfidf · element-wise 的將 vector 與 Idf_vector 相乘
## hint: 如果兩個 vector 的型別都是 np.array，把兩條 vector 相乘，就會自動把向量中的
#=====your works starts=====#
vector = vector * Idf_vector
#=====your works ends=====#
return vector

```

```

df_question['vector'] = df_question['processed'].apply(terms_to_vector)  ## 將上面定義
df_question['vector'][:10]
# 0    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 1    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 2    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 3    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 4    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 5    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 6    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 7    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 8    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# 9    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
# Name: vector, dtype: object

```

```

Out [24]: 0    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
1    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
2    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
3    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
4    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
5    [0.09420893837494694, 0.0, 0.0, 0.0, 0.0, 0.0, ...
6    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
7    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
8    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
9    [0.28262681512484084, 0.0, 0.0, 0.0, 0.0, 0.0, ...
Name: vector, dtype: object

```

```

In [25]: from numpy.linalg import norm

```

```

def cosine_similarity(vector1, vector2):  ## 定義 cosine 相似度的計算公式
# 使用 np.dot 與 norm 計算 cosine score
#=====your works starts=====#
score = np.dot(vector1, vector2) / (norm(vector1) * norm(vector2))
#=====your works ends=====#
return score

```

```

sentence1 = df_question.loc[0]  ## 取出第零個的問題
sentence2 = df_question.loc[2]  ## 取出第二個的問題
print(sentence1['question'])
print(sentence2['question'])

```

```
print(cosine_similarity(sentence1['vector'], sentence2['vector'])) ## 計算兩者的相似度
# 0.203227847937731
```

小孩出生後應於何時申請育兒津貼?
育兒津貼申請應備文件為何?
0.20322784793773094

```
In [26]: def retrieve(testing_sentence, return_num=3): ## 定義出檢索引擎
# 請使用前面定義的 terms_to_vector 與 preprocess 兩個 function · 計算出 testing_sentence 的 vector
# 計算其與資料庫每一的問句的相似度
# 依分數進行排序 · 找到分數最高的三個句子
#=====your works starts=====#
testing_vector = terms_to_vector(preprocess(testing_sentence)) ## 把剛剛的前處理的 sentence 轉成 vector
idx_score_mapping = [(idx, cosine_similarity(testing_vector, vec)) for idx, vec in df_question['vector'].items()]
top3_idxes = np.array(sorted(idx_score_mapping, key=lambda x:x[1], reverse=True))[:3]
#=====your works ends=====#

return df_question.loc[top3_idxes, ['question', 'ans']]
```

```
print(retrieve("老人年金").index)
# Float64Index([100.0, 111.0, 321.0], dtype='float64')
```

```
Float64Index([100.0, 111.0, 321.0], dtype='float64')
```

5 Use Scikit learn

```
In [27]: from sklearn.feature_extraction.text import TfidfVectorizer
```

```
In [28]: tfidf = TfidfVectorizer()
# 使用 tfidf.fit_transform 將轉換 df_question['processed'] 為 vector
#=====your works starts=====#
df_question['sklearn_vector'] = list(tfidf.fit_transform(df_question['processed']).apply(lambda x: x.toarray()[0]))
#=====your works ends=====#

print(df_question.loc[:10, 'sklearn_vector'].apply(sum).values)
# [2.54619627 2.54619627 1.95695906 3.12409736 2.19106254 2.74144953
# 3.82923767 2.54569516 3.4163518 2.98088982 2.35528293]
```

```
[2.54619627 2.54619627 1.95695906 3.12409736 2.19106254 2.74144953
3.82923767 2.54569516 3.4163518 2.98088982 2.35528293]
```

```
In [29]: def sklearn_retrieve(testing_sentence, return_num=3): ## 定義出檢索引擎
# 請使用前面定義的 tfidf.transform 與 preprocess 兩個 function · 計算出 testing_sentence 的 vector
# 注意 tfidf.transform 必須是兩個維度的 array
```



```

# 且 out 為 sparse metric，必需.toarray() 轉換為一般 np.array()
# 計算其與資料庫每一問句的相似度
# 依分數進行排序，找到分數最高的三個句子
#=====your works starts=====#
testing_vector = tfidf.transform([" ".join(preprocess(testing_sentence))]).toarray()
idx_score_mapping = [(idx, cosine_similarity(testing_vector, vec)) for idx, vec in enumerate(docs)]
top3_idx = np.array(sorted(idx_score_mapping, key=lambda x: x[1], reverse=True))
#=====your works ends=====#
return df_question.loc[top3_idx, ['question', 'ans']]

print(retrieve("老人年金")['question'])
print(sklearn_retrieve("老人年金")['question'])
# 100.0 我已經年滿 65 歲領有國民年金老人年金及基本保證年金 3628 元，因家境清寒還可以再
# 111.0 新竹市老人一般可領老人津貼 6628 元，該如何申請？
# 321.0 國民年金保險被保險人如果是家庭收入較低者，國民年金保險費是否可以減免？補助標準為何？
# Name: question, dtype: object
# 100.0 我已經年滿 65 歲領有國民年金老人年金及基本保證年金 3628 元，因家境清寒還可以再
# 111.0 新竹市老人一般可領老人津貼 6628 元，該如何申請？
# 321.0 國民年金保險被保險人如果是家庭收入較低者，國民年金保險費是否可以減免？補助標準為何？
# Name: question, dtype: object

100.0 我已經年滿 65 歲領有國民年金老人年金及基本保證年金 3628 元，因家境清寒還可以再申請中低收入
111.0 新竹市老人一般可領老人津貼 6628 元，該如何申請？
321.0 國民年金保險被保險人如果是家庭收入較低者，國民年金保險費是否可以減免？補助標準為何？
Name: question, dtype: object
100.0 我已經年滿 65 歲領有國民年金老人年金及基本保證年金 3628 元，因家境清寒還可以再申請中低收入
111.0 新竹市老人一般可領老人津貼 6628 元，該如何申請？
321.0 國民年金保險被保險人如果是家庭收入較低者，國民年金保險費是否可以減免？補助標準為何？
Name: question, dtype: object

In [30]: print(retrieve("托育")['question'])
print(sklearn_retrieve("托育")['question'])

15.0 托育費用補助對象為何？
14.0 托育費用補助標準為何？
19.0 要申請托育補助一定要找加入居家托育服務中心的托育人員嗎？
Name: question, dtype: object
0.0 小孩出生後應於何時申請育兒津貼？
1.0 小孩出生後應於何時申請育兒津貼？
2.0 育兒津貼申請應備文件為何？
Name: question, dtype: object

In [31]: print(retrieve("補助")['question'])
print(sklearn_retrieve("補助")['question'])

```



```
214.0          中低收入醫療補助補助項目及標準為何？
108.0          申請假牙補助的資格及補助內容
82.0          特殊境遇家庭法律訴訟補助如何申請？補助額度如何？
Name: question, dtype: object
108.0          申請假牙補助的資格及補助內容
15.0          托育費用補助對象為何？
214.0          中低收入醫療補助補助項目及標準為何？
Name: question, dtype: object
```

```
In [32]: print(retrieve("救助")['question'])
         print(sklearn_retrieve("救助")['question'])
```

```
204.0          社會福利-急難救助核發救助對象？
74.0          遭遇特殊境遇家庭如何申請救助（申請方式）？
203.0          社會福利-我要到那裡申請急難救助？
Name: question, dtype: object
204.0          社會福利-急難救助核發救助對象？
203.0          社會福利-我要到那裡申請急難救助？
74.0          遭遇特殊境遇家庭如何申請救助（申請方式）？
Name: question, dtype: object
```

```
In [ ]:
```