

03ClusteringTheory

November 10, 2018

1 分群 (Clustering)

1. 目標:
 - 群內相似度很高
 - 群間相似度很低
2. 主要影響因子:
 - 相似度的衡量與實作
 - 「群」的定義
 - 演算法
3. 應用面:
 - 市場區隔
 - 生物分群
 - 新聞分群

2 距離的定義

1. Euclidean distance(歐基里德距離)

$$\bullet d(i, j) = \sqrt{|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \cdots + |x_{in} - x_{jn}|^2}$$

2. Manhattan (city block) distance(曼哈頓距離)

$$\bullet d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{in} - x_{jn}|$$

3. Minkowski distance

$$\bullet d(i, j) = \sqrt[q]{|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \cdots + |x_{in} - x_{jn}|^q}$$

4. Weighted Manhattan distance(加權曼哈頓距離)

$$\bullet d(i, j) = \sqrt[q]{w1|x_{i1} - x_{j1}|^q + w2|x_{i2} - x_{j2}|^q + \cdots + w3|x_{in} - x_{jn}|^q}$$

3 IMPORT & DATA

```
In [1]: import matplotlib.pyplot as plt
        from planar_utils import plot_decision_boundary, sigmoid, load_planar_dataset, load_ext
        import numpy as np
        np.random.seed(1212)

        import os
        from collections import Counter
        import pandas as pd


        from load_all_datasets import load
        from sklearn.cluster import KMeans, AgglomerativeClustering, DBSCAN

        from mpl_toolkits.mplot3d import Axes3D
        from sklearn import datasets
        from sklearn.decomposition import PCA

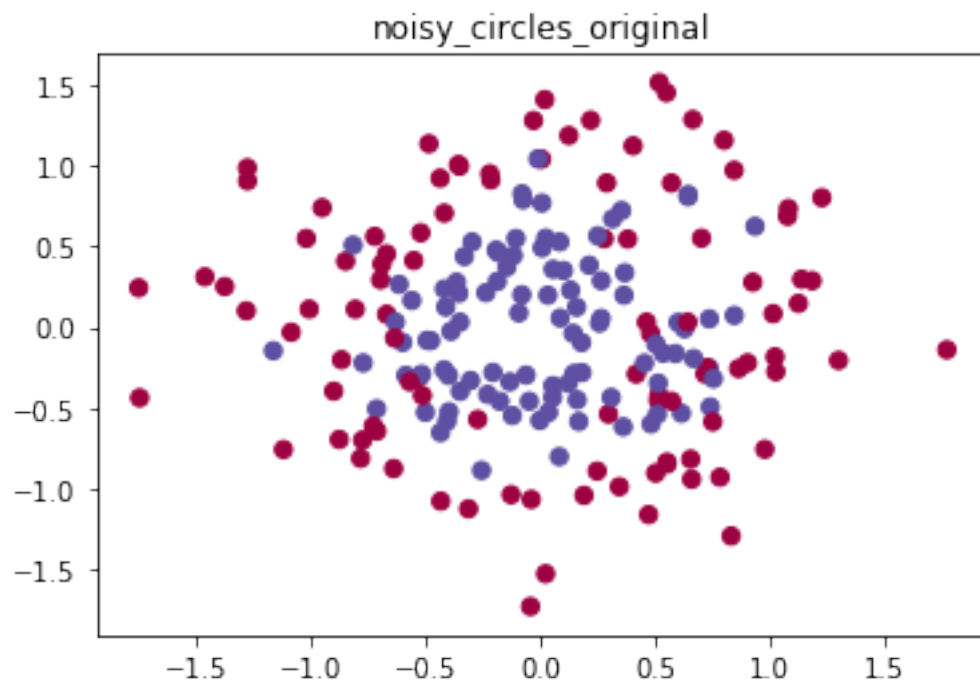
In [2]: # demo 用資料
        datas = load()

        for name, X, Y in datas:
            print(name)
            plt.scatter(X[:, 0], X[:, 1], c=Y, s=40, cmap=plt.cm.Spectral);
            plt.title(name+'_original')
            plt.show()
```

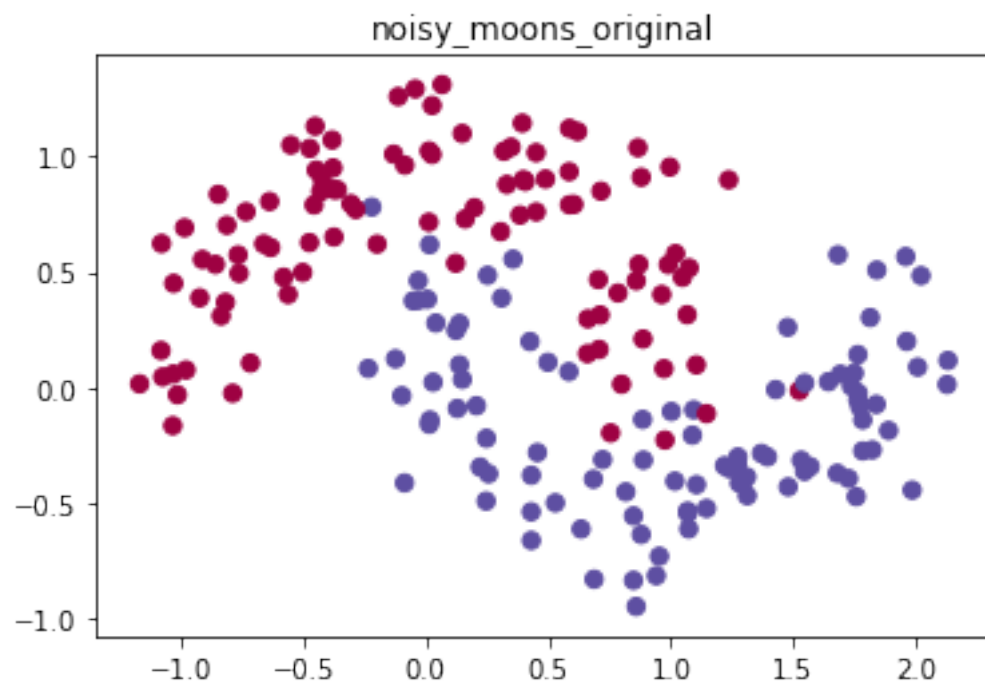
flower



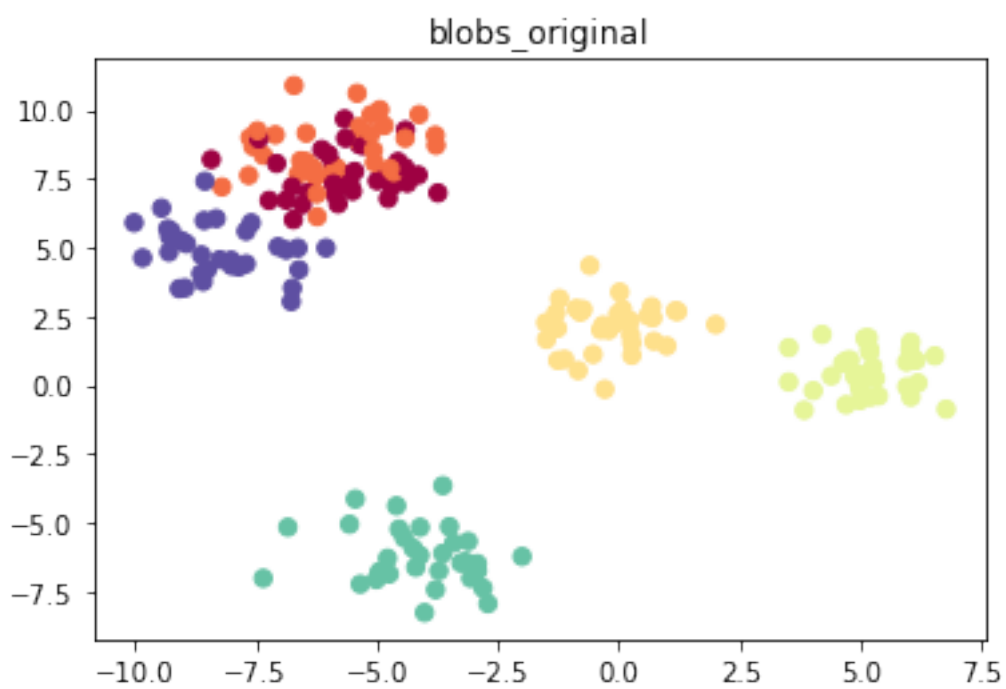
noisy_circles



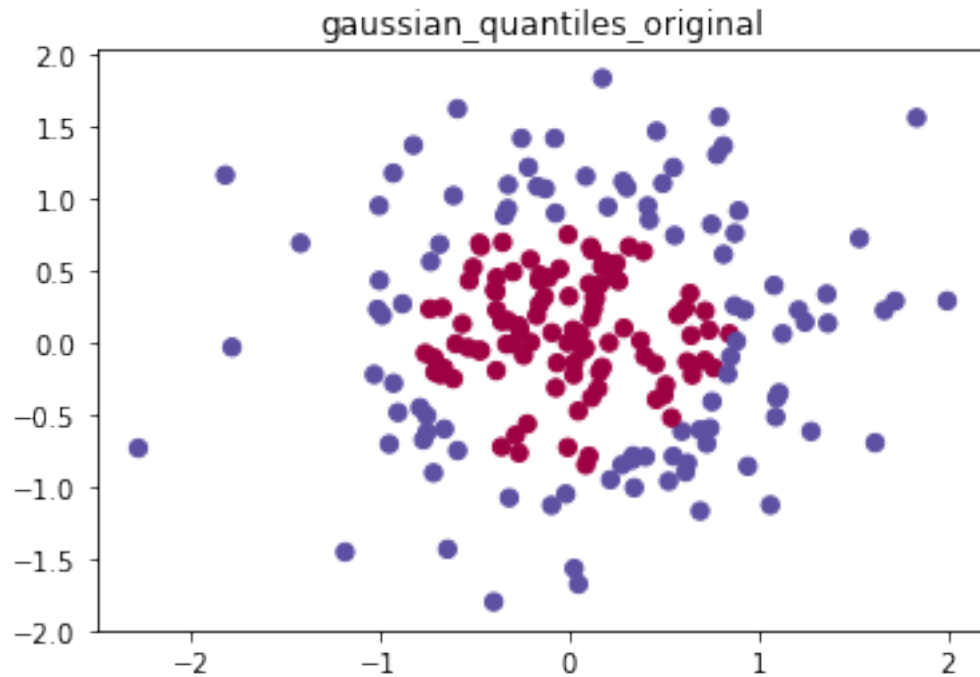
noisy_moons



blobs



gaussian_quantiles



In [3]: # 練習用資料

```
iris = datasets.load_iris()
df_iris = pd.DataFrame(iris.data, columns=iris['feature_names'])
df_iris['target'] = list(map(lambda x:iris.target_names[x], iris.target))
df_iris.head()
```

```
Out[3]:
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	\
0	5.1	3.5	1.4	0.2	
1	4.9	3.0	1.4	0.2	
2	4.7	3.2	1.3	0.2	
3	4.6	3.1	1.5	0.2	
4	5.0	3.6	1.4	0.2	

	target
0	setosa
1	setosa
2	setosa
3	setosa
4	setosa

In [4]: # 簡單資料探索

請找出每一個 *target* (花的類別) 的種類各有幾筆資料 (*hint: groupby*)

```
#!=====your works starts=====!#
```

```
#!=====your works ends=====!#
```


```
Out [4]:          sepal length (cm)  sepal width (cm)  petal length (cm)  \
target
setosa                50                50                50
versicolor            50                50                50
virginica              50                50                50

          petal width (cm)
target
setosa                50
versicolor            50
virginica              50
```

```
In [5]: # 請畫出 ['sepal length (cm)'] 的分布狀況
#!=====your works starts=====!#

#!=====your works ends=====!#

plt.show()
```




```
In [6]: iris_X = df_iris[["sepal length (cm)", "sepal width (cm)", "petal length (cm)", "petal
iris_Y = iris.target
X = iris_X
```

```
Y = iris_Y

# 請使用 PCA 畫出不同花在三維空間中的分布位置 (請上網尋找 PCA 的程式碼，並複製過來)
#!=====your works starts=====!#
```

```
#!=====your works ends=====!#

plt.show()
```



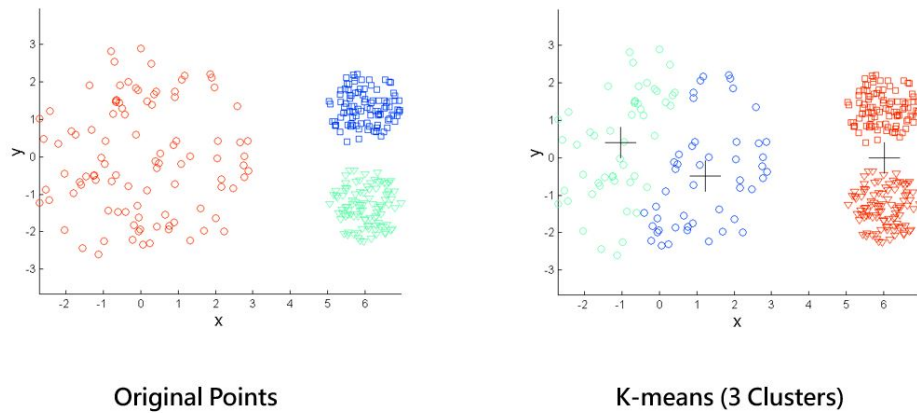
4 ALGORITHM

4.1 1. K-means

4.1.1 steps

1. 設定重心:
 - 決定要分幾個群 (e.g. K 群)
 - 隨機產生 K 個重心
2. 分群:
 - 找到所有資料點歸屬的重心: 找到分別最靠近這三個點的所有資料點，並做第一個迴圈的分群
3. 尋找重心:
 - 重新計算所有資料點的重心 (element-wise 的平均)
4.
5. 停止:
 - 重複上述方法，只到不會有資料點因為重新尋找重心而改變群組

kmeans



KmeansCon1.JPG

4.1.2 visualize

1. web:

[game](#)

2.

4.1.3 parameters

參數	意義
n_cluster	要分成幾個群
random_state	決定初始點的隨機 seed

4.1.4 pros & cons

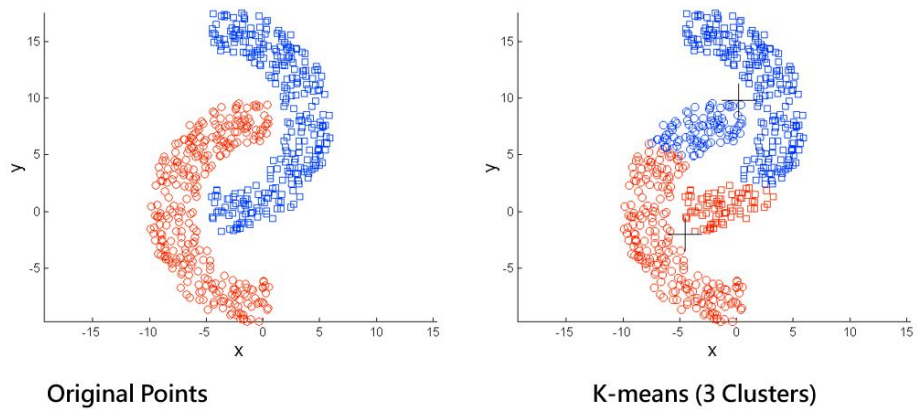
1. 一開始需要決定要分成幾個群

2. 優點

- 效率: 時間複雜度 $O(tkn)$ 。n 是資料點的個數，k 是群的個數，t 是迴圈的個數，一班來說: $k, t \ll n$ 。

3. 缺點

- 需要指定分成幾群
- 無法處理具有雜訊 (noisy) 的資料及離群值 (outliers)
- 無法處理不同大小及不同密度的群
- 無法發現凸多邊形 (non-convex) 以外的群



KmeansCon2.JPG

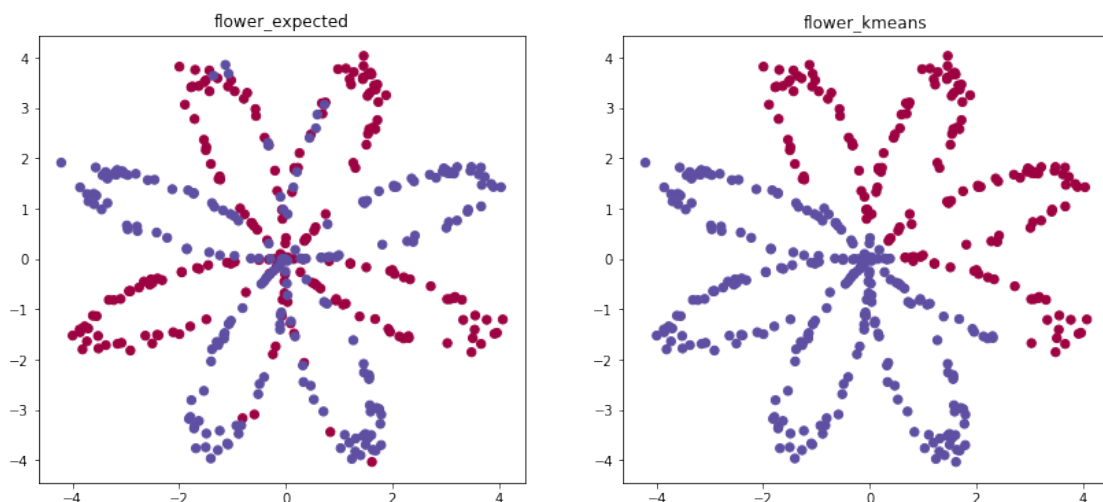
- 通常在 local optimum 停止


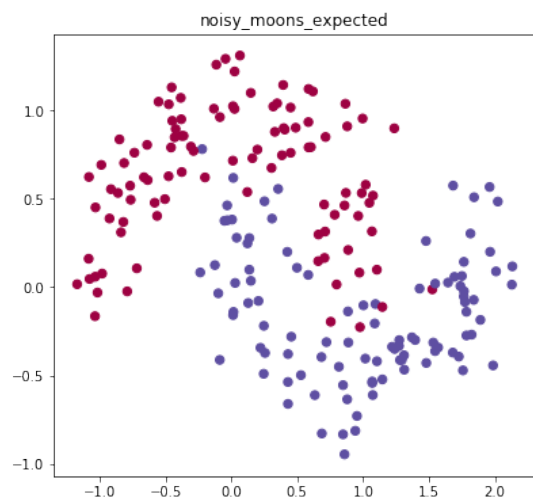


```
In [7]: for name, X, Y in datas:
        plt.figure(figsize=(14,6))

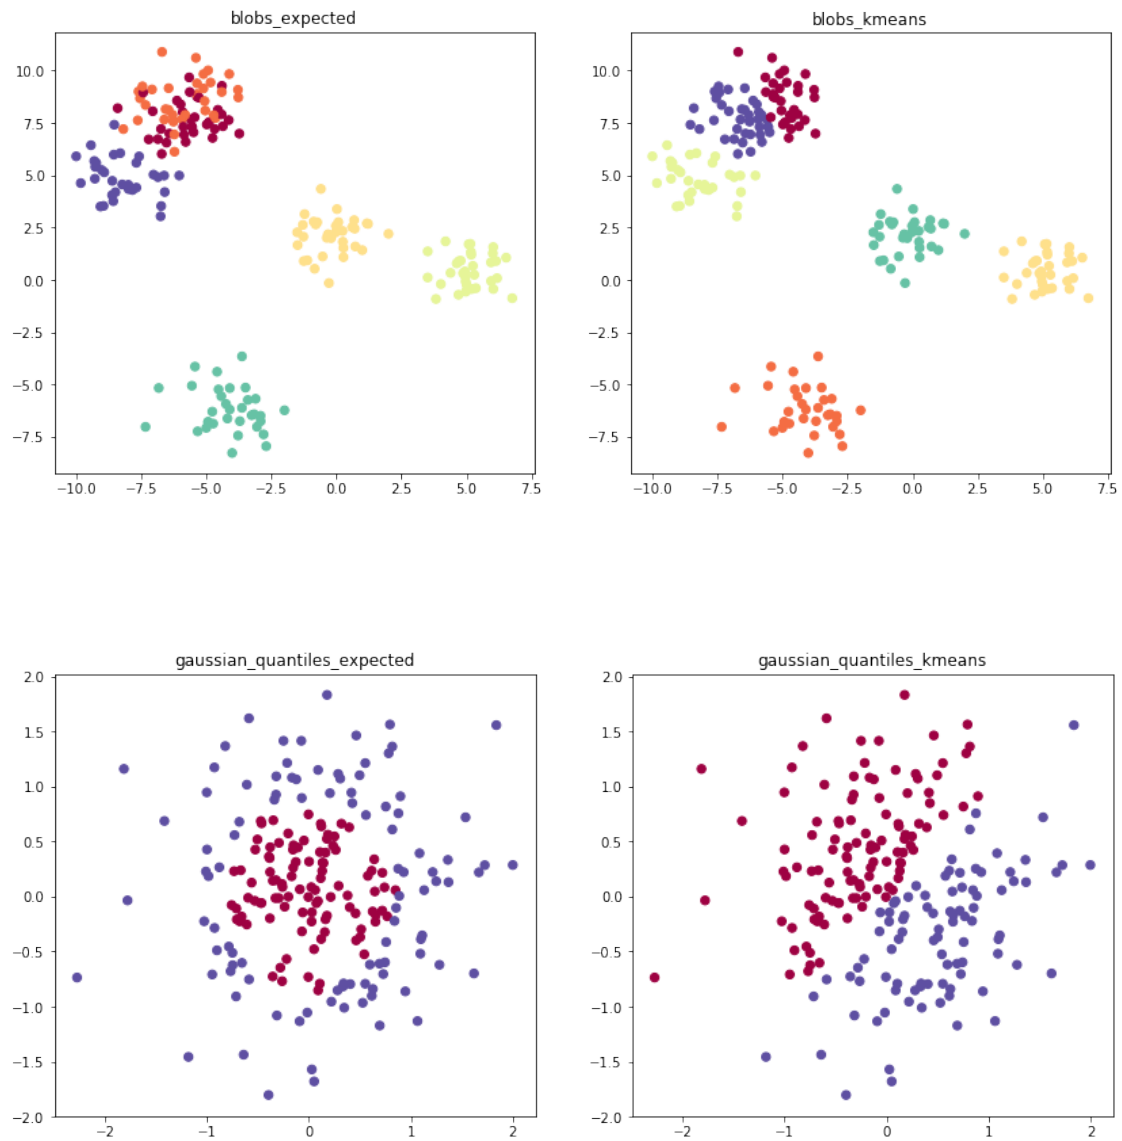
        axes1 = plt.subplot(1, 2, 1)
        axes1.scatter(X[:, 0], X[:, 1], c=Y, s=40, cmap=plt.cm.Spectral)
        plt.title(name + "_expected")

        axes2 = plt.subplot(1, 2, 2)
        n_clusters = len(set(Y))
        kmeans = KMeans(n_clusters=n_clusters, random_state=0).fit_predict(X)
        axes2.scatter(X[:, 0], X[:, 1], c=kmeans, s=40, cmap=plt.cm.Spectral);
        plt.title(name+'_kmeans')

        plt.show()
```







```
In [8]: # 請使用 kmeans 將 iris_X 進行分群 (注意:random_state=0)
#=====your works starts=====#
n_clusters =
kmeans_Y =
#=====your works ends=====#

np.random.seed(1212)
print(kmeans_Y[np.random.randint(149, size=10)])
# # [2 0 0 2 2 1 1 1 1 0]
```

```
[2 0 0 2 2 1 1 1 1 0]
```

```


In [9]: # actual
def plot_iris_predict_acc(predict_Y):
    X = iris_X
    Y = iris_Y
    fig = plt.figure(1, figsize=(16, 6))
    ax = fig.add_subplot(1, 2, 1, projection='3d')
    X_reduced = PCA(n_components=3).fit_transform(X)
    ax.scatter(X_reduced[:, 0], X_reduced[:, 1], X_reduced[:, 2], c=Y,
               cmap=plt.cm.Set1, edgecolor='k', s=40)
    ax.set_title("PCA with non-log(Fare)")
    ax.set_xlabel("1st eigenvector")
    ax.w_xaxis.set_ticklabels([])
    ax.set_ylabel("2nd eigenvector")
    ax.w_yaxis.set_ticklabels([])
    ax.set_zlabel("3rd eigenvector")
    ax.w_zaxis.set_ticklabels([])

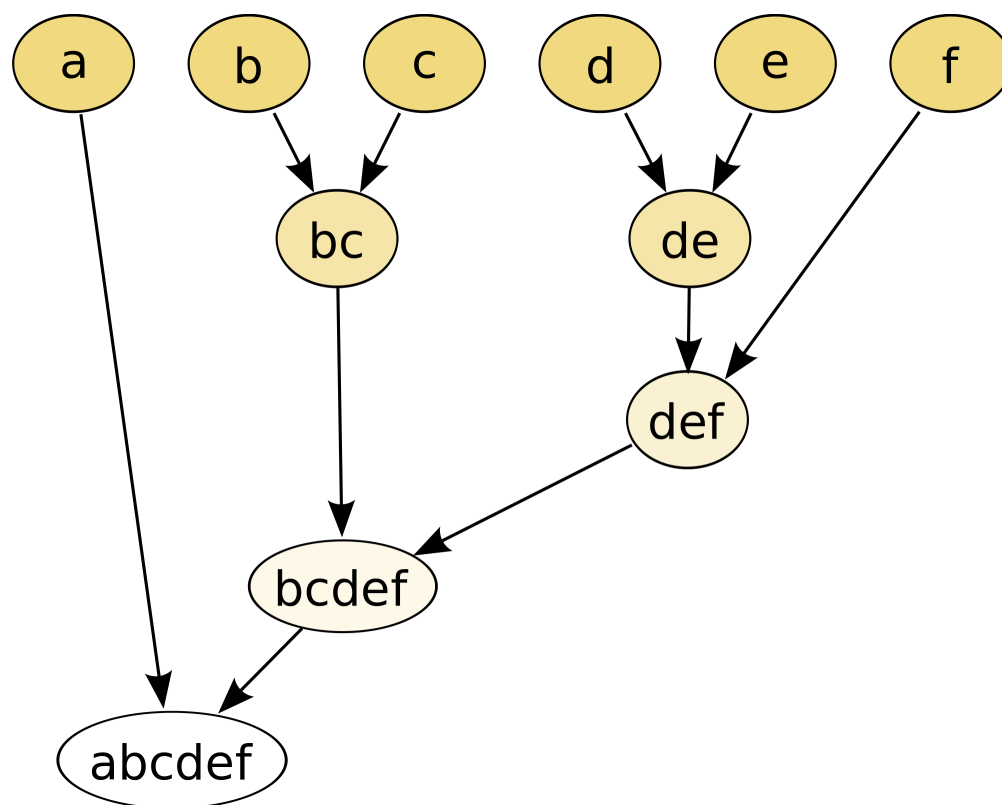
    # predict
    X = iris_X
    Y = predict_Y
    fig = plt.figure(1, figsize=(16, 6))
    ax = fig.add_subplot(1, 2, 2, projection='3d')
    X_reduced = PCA(n_components=3).fit_transform(X)
    ax.scatter(X_reduced[:, 0], X_reduced[:, 1], X_reduced[:, 2], c=Y,
               cmap=plt.cm.Set1, edgecolor='k', s=40)
    ax.set_title("PCA with non-log(Fare)")
    ax.set_xlabel("1st eigenvector")
    ax.w_xaxis.set_ticklabels([])
    ax.set_ylabel("2nd eigenvector")
    ax.w_yaxis.set_ticklabels([])
    ax.set_zlabel("3rd eigenvector")
    ax.w_zaxis.set_ticklabels([])

    plt.show()

np.random.seed(1212)
plot_iris_predict_acc(kmeans_Y)

```





hierarchical

4.2 2. Hierarchical Clustering

4.2.1 steps

hierarchical 的分群方法，步驟簡述如下，可參考下圖 (取自維基百科):

1. 把每一個點當作一個群組
2. 透過掃描過整個資料及尋找出最近的兩個群組，並把這兩個點再一起變成一個群組
3. 尋找下一個最近的兩個群組，再綁再一起變成一個群組
4.
5. 停止：直到所有資料都被分成一群，或是透過設定參數到分到幾個群時自動停止

4.2.2 parameters

1. table

參數	意義
linkage	如何衡量群與群之間的距離。(註解)
n_clusters	分成幾個群

2. 註解:

- ward(single): 兩個群中最近的點。
- complete: 兩個群中最遠的點。
- average: 兩個群的重心。

4.2.3 pros & cons

```

axes3 = plt.subplot(1, 4, 3)
n_clusters = len(set(Y))
hierarchy = AgglomerativeClustering(linkage=linkage[1], n_clusters=n_clusters).fit(X)
axes3.scatter(X[:, 0], X[:, 1], c=hierarchy, s=40, cmap=plt.cm.Spectral);
plt.title(name+'_' + linkage[1])

```

```

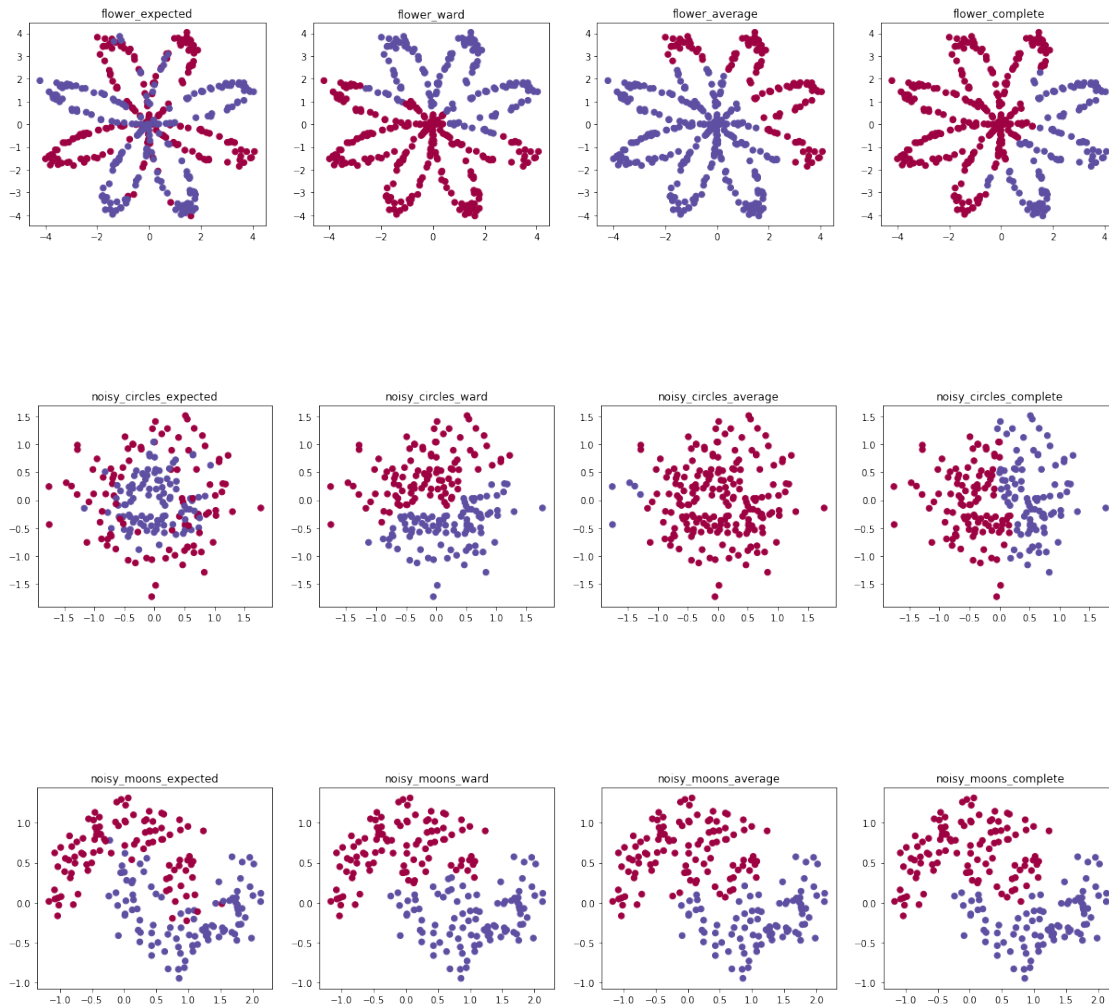
axes4 = plt.subplot(1, 4, 4)
n_clusters = len(set(Y))
hierarchy = AgglomerativeClustering(linkage=linkage[2], n_clusters=n_clusters).fit(X)
axes4.scatter(X[:, 0], X[:, 1], c=hierarchy, s=40, cmap=plt.cm.Spectral);
plt.title(name+'_' + linkage[2])


```

```

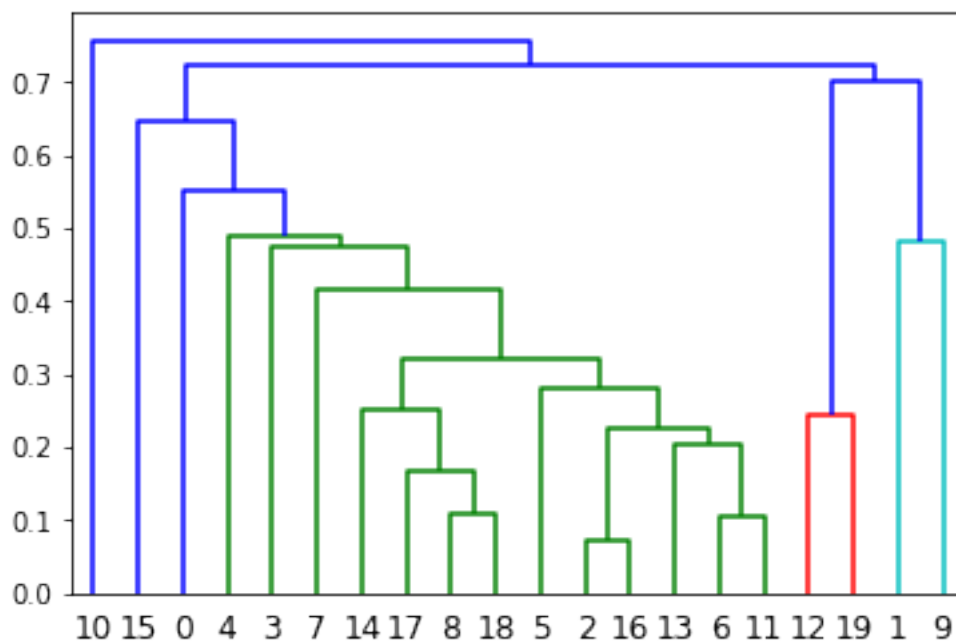
plt.show()

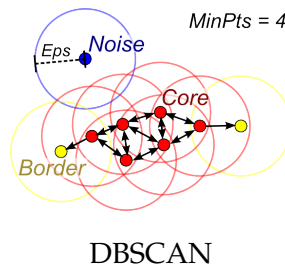
```





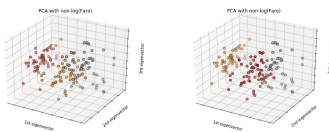
```
In [11]: # Other Method (参考就好)
from scipy.cluster.hierarchy import dendrogram, linkage
Z = linkage(X[:20], 'single')
plt.figure()
dn = dendrogram(Z)
plt.show()
```





```
In [12]: # 請用 AgglomerativeClustering(linkage='average') 將 iris_X 進行分群
#=====your works starts=====#
n_clusters =
hierarchy_Y =
#=====your works ends=====#

plot_iris_predict_acc(hierarchy_Y)
```



4.3 3. Density Based Clustering (DBSCAN)

4.3.1 steps

顧名思義，這種分群演算法計算的是密度，透過設定多長的半徑內，有出現幾個點，不斷延伸，延伸到無法延伸，所有出現在前面延伸範圍的點分成一個群組，請見下圖 (取自[stackexchange](https://stackoverflow.com/questions/2244512/dbSCAN-clustering))。

4.3.2 parameters

參數	意義
eps	半徑

4.3.3 pros & cons

1. 常常用來偵測 Noisy Data。
2. 無法設定要分成幾個群。

```
In [13]: epss = [0.3, 0.4, 0.5]
for name, X, Y in datas:
```

```
plt.figure(figsize=(21,4))
```

```
axes1 = plt.subplot(1, 4, 1)
axes1.scatter(X[:, 0], X[:, 1], c=Y, s=40, cmap=plt.cm.Spectral)
```



```

axes2 = plt.subplot(1, 4, 2)
dbscan = DBSCAN(eps=epss[0]).fit_predict(X)
axes2.scatter(X[:, 0], X[:, 1], c=dbscan, s=40, cmap=plt.cm.Spectral)
plt.title(name+'_'+str(epss[0]))

```

```

axes3 = plt.subplot(1, 4, 3)
dbscan = DBSCAN(eps=epss[1]).fit_predict(X)
axes3.scatter(X[:, 0], X[:, 1], c=dbscan, s=40, cmap=plt.cm.Spectral)
plt.title(name+'_'+str(epss[1]))

```

```

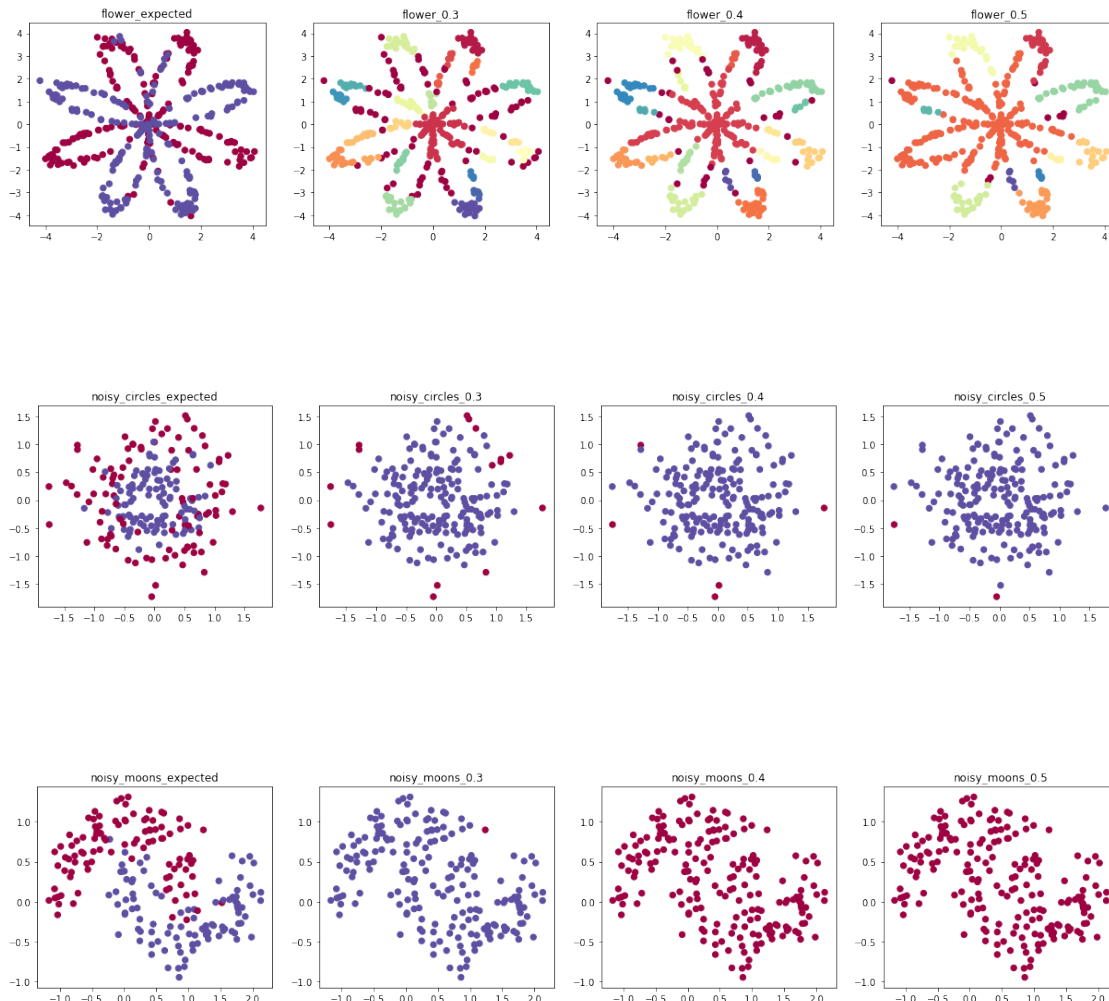
axes3 = plt.subplot(1, 4, 4)
dbscan = DBSCAN(eps=epss[2]).fit_predict(X)
axes3.scatter(X[:, 0], X[:, 1], c=dbscan, s=40, cmap=plt.cm.Spectral)
plt.title(name+'_'+str(epss[2]))

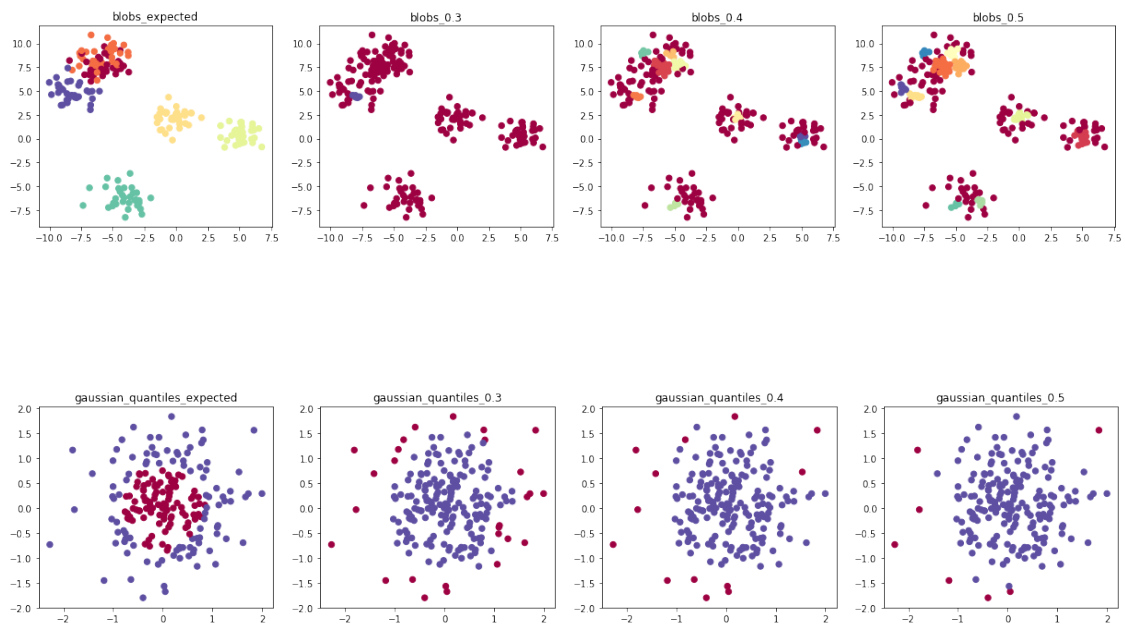
```

```

plt.show()

```





```
In [14]: # 請用 DBSCAN(eps=0l.3) 將 iris_X 進行分群
#=====your works starts=====#
dbscan_Y =
#=====your works ends=====#

plot_iris_predict_acc(dbscan_Y)
```

